日本語LLMのための再現可能な検証基盤設計

AETS 伊藤あきら

背景と問題意識 (BACKGROUND AND PROBLEMS)

アカツキちゃん ©AETS

「過去最高！」

この言葉の真の意味は何なのか？

代表的なAIモデルとその性能測定方法および実行条件公表状況

Model/Vendor	Index	Feature	Source
GPT-4/OpenAI	MMLU/HumanEval/GSM8K/BIG-Bench	**スコアは出すが 実験条件はほぼ非公開**	GPT-4 Technical Report (OpenAI, 2023)
Claude/Anthoropic	MMLU/GSM8K/HumanEval/GPQA	**評価スコア中心 実行条件非公開**	Claude 3 Model Card / Technical Report (Anthropic, 2024)
DeepSeek-R1/DeepSeek	AIME/MATH/Codeforces/MMLU/SWE-bench	**推論能力ベンチ中心 実行条件非公開**	DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning (DeepSeek-AI, 2025)
LLaMA/Meta	MMLU/GSM8K/HumanEval/TuthfulQA	**評価スコア中心 実行条件は限定的公開**	LLaMA: Open and Efficient Foundation Language Models (Meta, 2023) / Llama 3 Technical Report (Meta, 2024)

数年前と比べると、AIの性能は…

- LLMは日々"高性能"化
- でも日本語性能は？
- そもそも、その"高性能"とは何か？
- "高性能"を出すのに必要なものは？
- 正直、性能に満足してますか…？

アカツキちゃん ©AETS

「点数競争」だけ では足りない！

- どんなパラメータ？
- どんなプロンプト？
- どんなGPUで、どんなVRAM構成？
- アーキテクチャは？
- バックエンドは？

前提不明では正確な比較が不可能

アカツキちゃん ©AETS

科学的主張は反証可能でなければならない。
そのためには実験の完全な透明性と
再現性が必要不可欠である。

(Elechanan Mossel : The Refutability Gap: Challenges in ValidatingReasoning by Large Language Models/2025)

<u>Artifact First</u>な評価基盤が必要

着眼点
(INSIGHT)

アカツキちゃん ©AETS

今回作ったものの本質

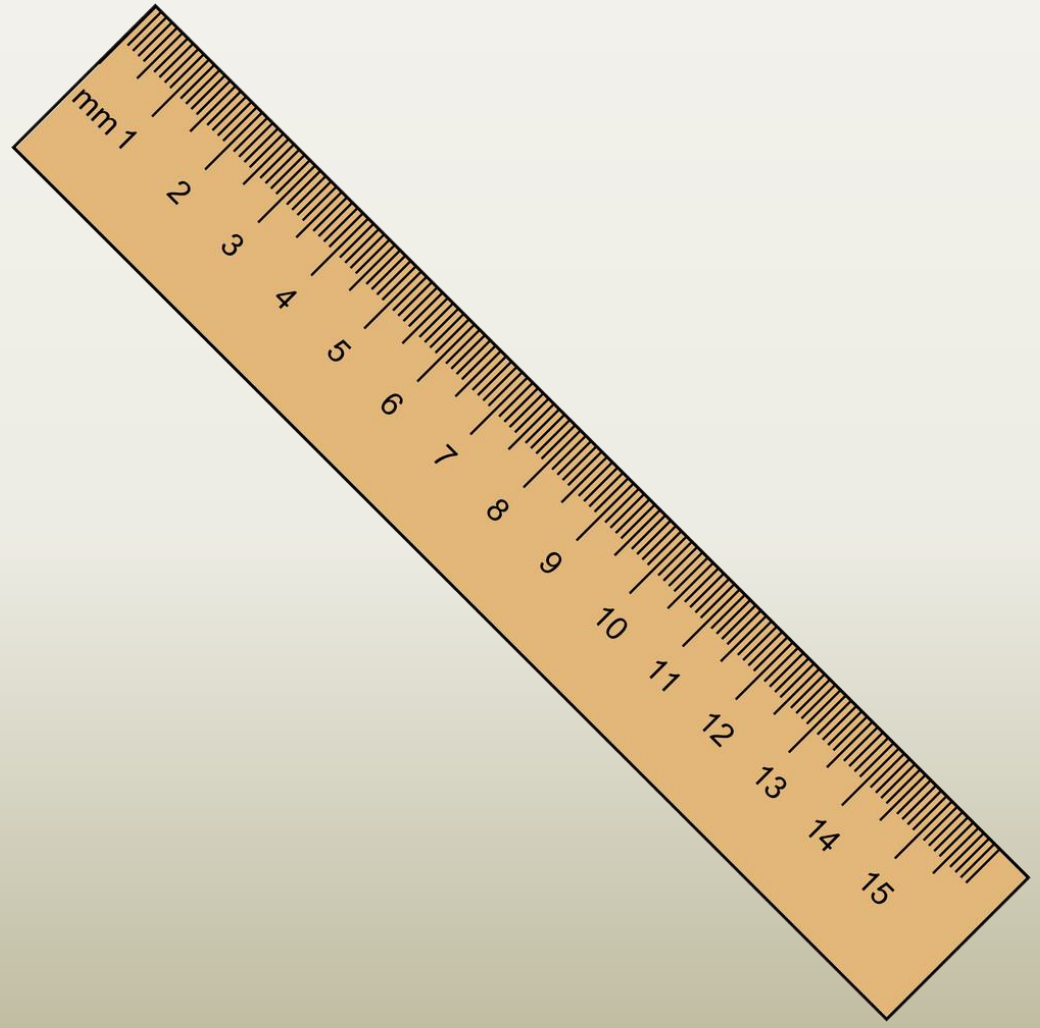

条件差異に敏感なモデルを利用

DeepSeek R1 は
MoE (Mixture-of-Experts) と
MLA (Multi-Head Latent Attention)
という特殊な構造を持つため

- **Expert routing**
- **KV compression**

等の処理が発生し、
GPU / backend / runtime などの
実行環境差の影響を比較的受けやすい。
Switch Transformer (Fedus et al., 2021) でも
Mixture-of-Experts における routing により
conditional computation が発生することが
指摘されている。

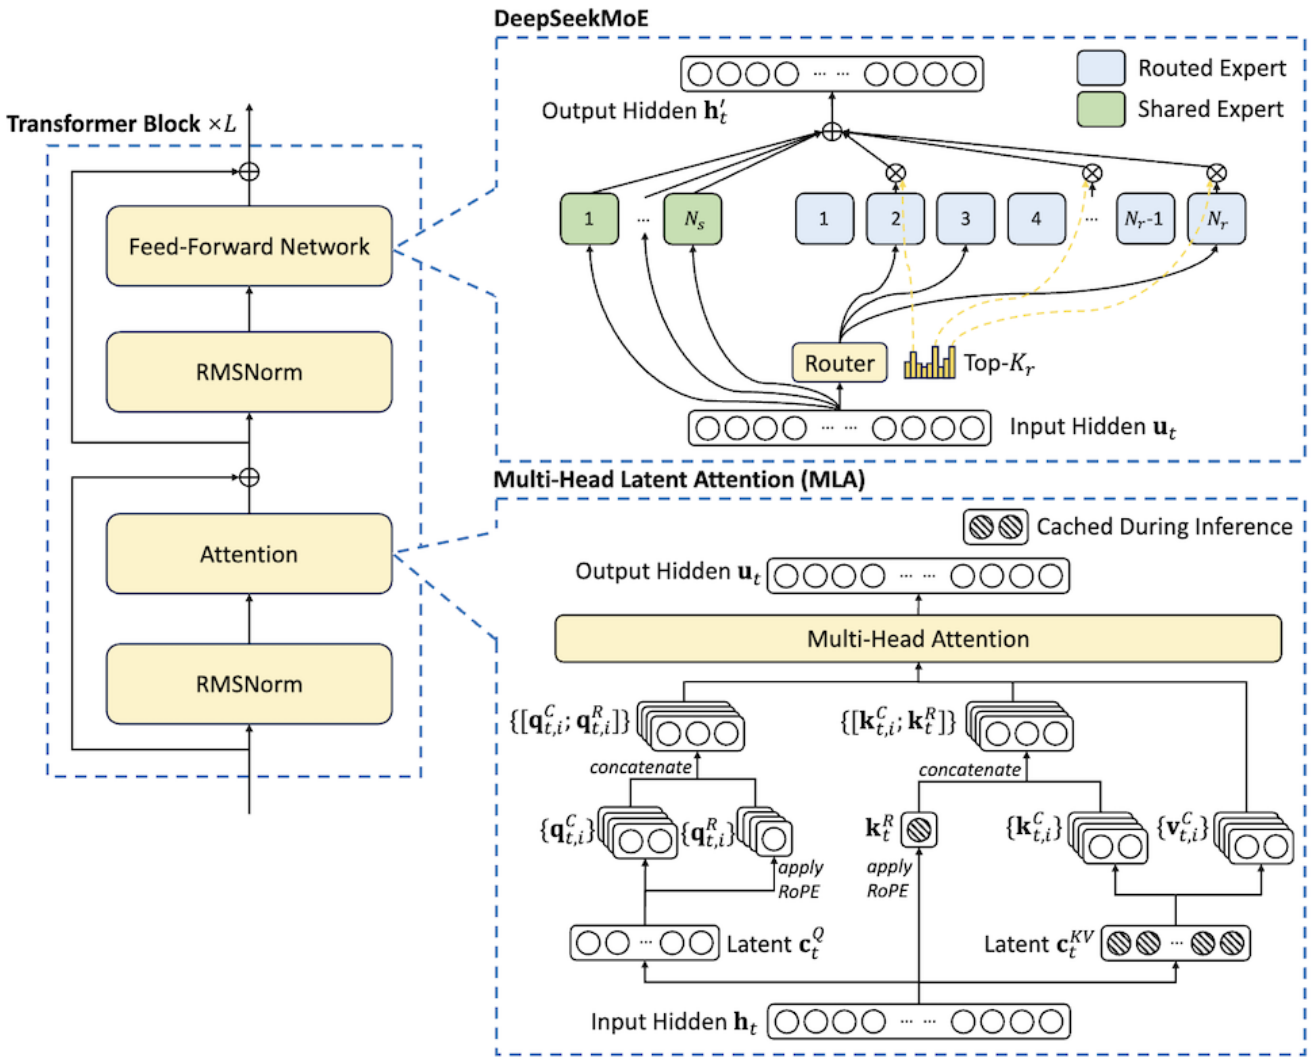

Figure 2 | Illustration of the basic architecture of DeepSeek-V3. Following DeepSeek-V2, we adopt MLA and DeepSeekMoE for efficient inference and economical training.

DeepSeek-V3 Technical Report(arXiv:2412.19437)

提案手法：
証拠を全て残す
検証基盤MAGI

Control node と Runner node を分離し、
Runner 上での実行を Control node が管理する
ことで**実行条件の揺らぎを抑制する。**

さらに、すべての実行について
Unified JSON 形式でログを保存することで

- 実行環境
- 推論結果
- メタデータ

を詳細に記録し、
同一条件での再実行を保証する。

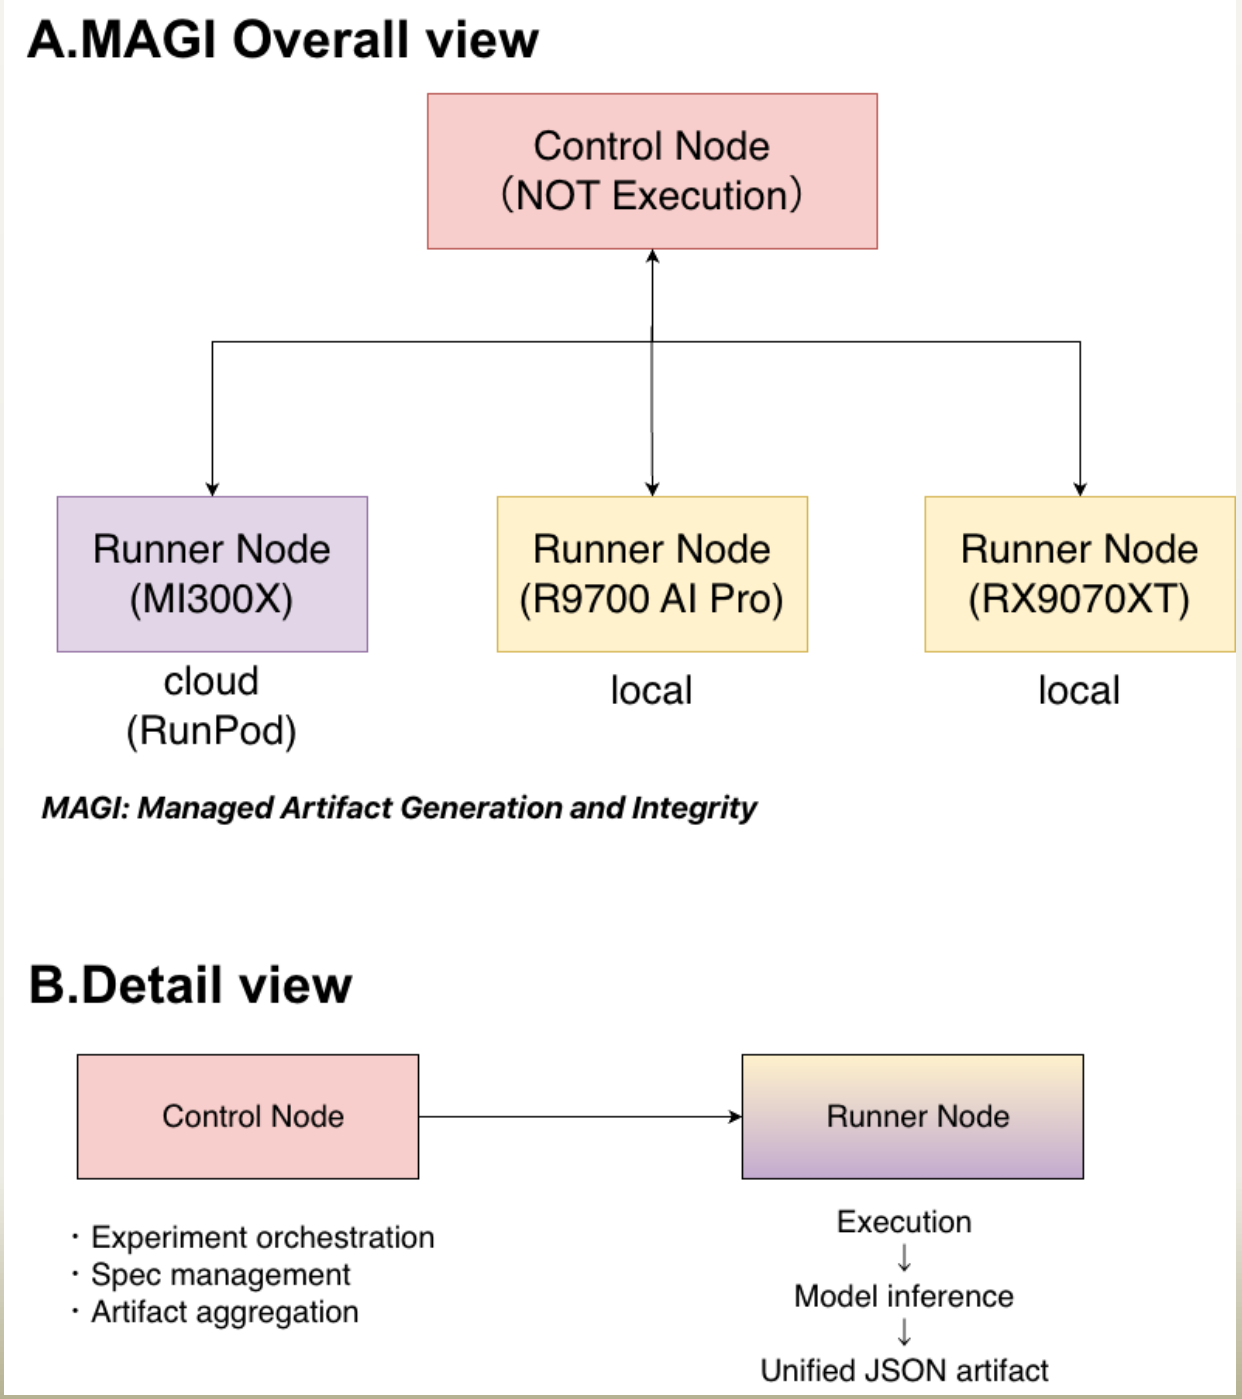

検証基盤を実装して実験を実施

MAGI

Managed Artifact Generation and Integrity

1. MAGI検証基盤を実装
2. 複数GPU環境で推論を実行
3. 約6,800出力を収集し統計解析(PythonとRのクロス検定)

DeepSeek-R1 on AMD GPU：出力品質の言語・HW・モデルサイズ依存性

110問（EN/JA）× 複数run → 総出力 6,862 ｜ 7B / 32B / Qwen3.5-9B ｜ T=0–0.7 ｜ EVE(R9700 AI Pro, ROCm7.2) / Zorya(RX9070XT, ROCm7.2) / MI300X(RunPod)

A. 7B：言語 × ハードウェア比較（T = 0）

傾向はGPUによらず同じ

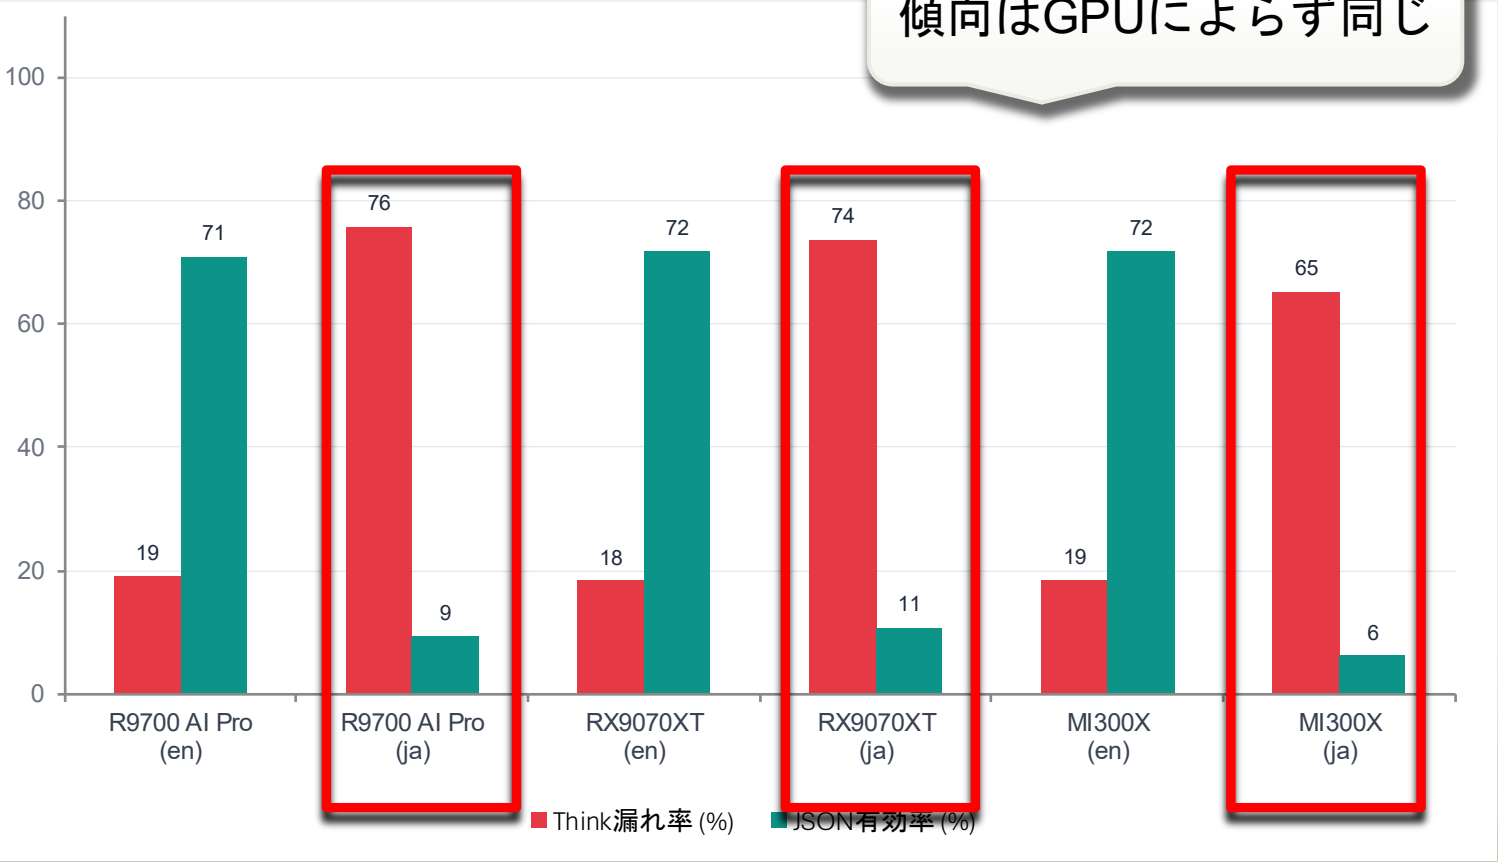

★ 言語効果は<u>ハードウェア非依存</u>：EN ≈ 19% 漏れ / 71% 有効　vs　JA ≈ 72% 漏れ / 9% 有効
（R9700 AI Pro・RX9070XT・MI300X すべて同様）

B. モデルサイズ比較（MI300X, T = 0）

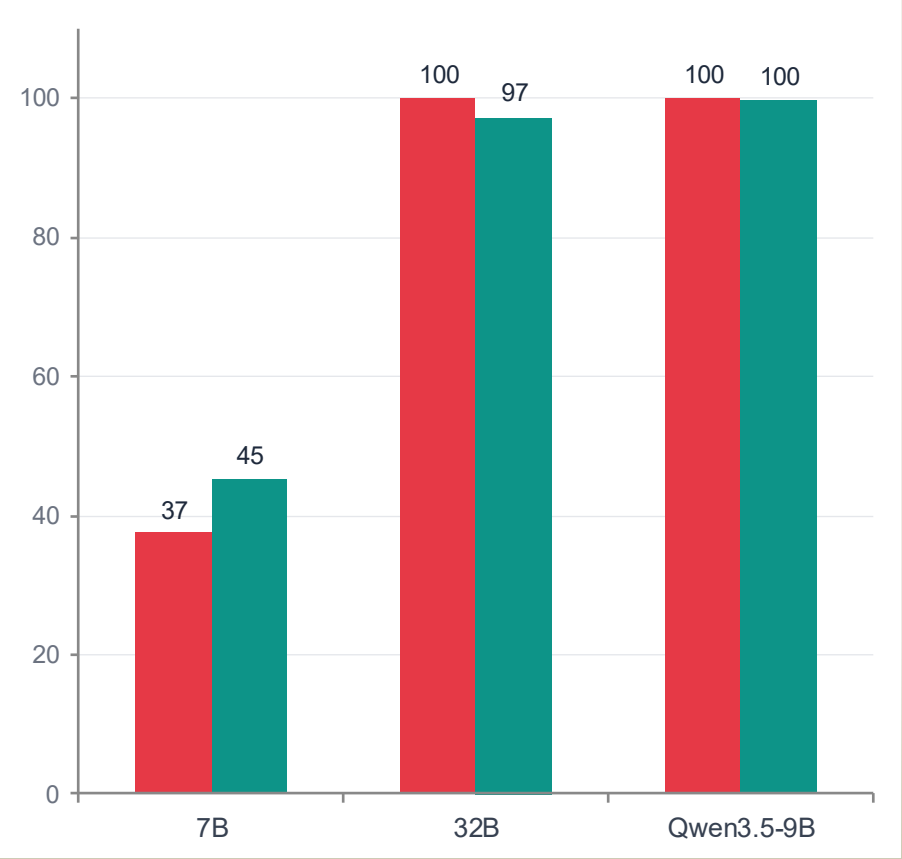

★ ラージモデルも think は漏れる
32B/Qwen3.5は Thinking…done thinking. 形式で100%漏出
JSON有効率は97–100%と改善

Wilson 95% CI ｜ Fisher exact (two-sided) ｜ Think漏れ×lang (7B): EVE OR=0.075 / Zorya OR=0.081 / MI300X OR=0.120 (all p<0.001) ｜ JSON×lang: EVE OR=23.5 / Zorya OR=21.2 / MI300X OR=38.6 (all p<0.001) ｜ 32B/Qwen3.5: think 100%漏出（Thinking…done thinking. 形式）｜ ROCm 7.2（EVE・Zorya）/ ROCm 6.3（MI300X, RunPod）/ Ollama

大発見！日本語では構造化出力の制御が壊れやすい！

主要比較：7B × T=0（EN vs JA） ｜ 110問 × 複数run → 総出力 6,862（T=0–0.7, 3 GPU, 3 モデル）

日本語より英語の方が
24.6倍も構造化出力を守る！！

▶ **Key Finding:** 推論能力の差ではなく「**JSON/think制御**」に言語依存のボトルネックが存在

3 GPU すべてで一貫した言語効果
EVE / Zorya / MI300X で同傾向 → GPU ではなく**モデル重みに起因**

日本語で JSON 指示に従わない
EN: JSON 有効 71% vs JA: 9% → OR ≈ 24.6, $p < 0.001$

日本語で think タグ抑制が困難
EN: think 漏洩 ≈ 19% vs JA: ≈ 72% → **言語がシステムプロンプト制御を弱める**

モデルサイズ大型化で JSON 問題は解決
32B / Qwen3.5-9B: JSON 97–100% → ただし think 漏洩は形式として残る

POINT!!

Key Statistics
JSON × Language（7B, T=0）

24.6 × (OR)

$p < 0.001$ ｜ Fisher exact

Think Leak (7B)

EN 19% vs **JA 72%**

32B / Qwen3.5-9B: JSON

97–100%

アカツキちゃん ©AETS

★ **Takeaway:** 日本語 × 小型 LLM の構造化出力設計には **think / JSON 制御の対策が必須**

Wilson 95% CI ｜ Fisher exact (two-sided) ｜ JSON×lang（7B, T=0）: EVE OR=23.5 / MI300X OR=38.6；Zorya OR=21.2（全T集計）(all $p<0.001$) ｜ Think×lang: EVE OR=0.075 / Zorya OR=0.081 / MI300X OR=0.120 ｜ HW 精度差: $p \approx 0.18$（有意差なし） ｜ ROCm 7.2（EVE・Zorya）/ ROCm 6.3（MI300X, RunPod）/ Ollama

まとめ

- LLM評価には再現可能な検証基盤が重要
- 日本語では構造化出力制御が崩れ易い
- 言語依存の出力制御問題の可能性

アカツキちゃん ©AETS

Thank you for your attention.
Questions are welcome.